

# ML Snippets

s.pol

# Оглавление

<b>1</b>	<b>Математика</b>	<b>6</b>
1.1	Случайная величина . . . . .	6
1.2	Распределение случайной величины . . . . .	6
1.3	Выборка . . . . .	7
1.4	Закон больших чисел . . . . .	7
1.5	Центральная предельная теорема . . . . .	7
1.6	Приближенное вычисление интегралов . . . . .	8
1.7	Статистики . . . . .	8
1.8	Bootstrap . . . . .	8
1.9	Классический и байесовский подход . . . . .	9
1.10	Классическая оценка параметров: MLE . . . . .	9
1.11	Байесовская оценка параметров: MAP . . . . .	10
1.12	Сравнение классической и байесовской оценок параметров . . . . .	10
1.13	Классический доверительный интервал . . . . .	11
1.14	Байесовский доверительный интервал . . . . .	11
1.15	Основные дискретные распределения . . . . .	11
1.16	Основные непрерывные распределения . . . . .	11
1.17	Метод Монте-Карло . . . . .	11
1.18	Байесовская оптимизация . . . . .	11
1.19	Матричные разложения . . . . .	11
1.20	К-Л дивергенция . . . . .	11
1.21	Энтропия . . . . .	12
1.22	Кросс-энтропия . . . . .	12
1.23	Квантили . . . . .	12
1.24	Точечные оценки . . . . .	12
1.25	Интервальные оценки . . . . .	12
1.26	Проверка гипотез *** . . . . .	12
1.27	Достижимый уровень значимости, $p_{value}$ *** . . . . .	13
1.28	Множественная проверка гипотез . . . . .	13
1.29	Коррекции на множественную проверку гипотез . . . . .	14
1.30	Ошибки I и II рода . . . . .	14
1.31	Уровень значимости, $\alpha$ . . . . .	14
1.32	Мощность статистического критерия . . . . .	14

1.33	Основные задачи статистики . . . . .	14
1.34	Параметрические и непараметрические критерии, бутстреп . . . . .	15
1.35	Проверка основных гипотез . . . . .	15
1.36	Корреляция Пирсона . . . . .	15
1.37	Корреляция Спирмена . . . . .	15
1.38	Корреляция Метьюса . . . . .	15
1.39	Корреляция Крамера . . . . .	15
1.40	Z-тест Фишера . . . . .	15
1.41	T-тест Стьюдента . . . . .	15
1.42	Критерий Пирсона $\chi^2$ . . . . .	15
1.43	Точный тест Фишера . . . . .	15
1.44	Проклятье размерности . . . . .	15
<b>2</b>	<b>Анализ данных</b>	<b>16</b>
2.1	Типы данных . . . . .	16
2.2	Предобработка данных . . . . .	16
2.3	Понижение размерности . . . . .	16
<b>3</b>	<b>Общие вопросы</b>	<b>17</b>
3.1	Машинное обучение . . . . .	17
3.2	Эмпирический риск . . . . .	17
3.3	Основные классы задач . . . . .	18
3.3.1	Обучение с учителем . . . . .	18
3.3.2	Обучение без учителя . . . . .	18
3.3.3	Частичное обучение . . . . .	18
3.3.4	Обучение с подкреплением . . . . .	18
3.4	Обнаружение аномалий . . . . .	18
3.5	Контроль качества . . . . .	18
3.6	Недообучение . . . . .	19
3.7	Переобучение . . . . .	19
3.8	Регуляризация . . . . .	19
3.9	Отбор признаков . . . . .	19
3.10	Параметры алгоритма . . . . .	19
3.11	Подбора метапараметров . . . . .	19
3.12	Основные типы алгоритмов . . . . .	19
3.13	Многоклассовая классификация . . . . .	19
3.14	Дисбаланс классов . . . . .	20
3.15	Ансамбли алгоритмов . . . . .	20
3.16	Метрики и функции потерь . . . . .	20
3.17	Метрики бинарной классификации . . . . .	20
3.17.1	Accuracy . . . . .	21
3.17.2	Precision . . . . .	21
3.17.3	Полнота (recall) . . . . .	21

3.17.4	F1-мера . . . . .	21
3.17.5	F-мера . . . . .	22
3.17.6	ROC кривая . . . . .	22
3.17.7	ROC-AUC . . . . .	23
3.17.8	PR кривая . . . . .	23
3.17.9	PR-AUC . . . . .	24
3.17.10	Бинарная кросс-энтропия (logloss) . . . . .	24
3.18	Метрики многоклассовой классификации . . . . .	25
3.18.1	Категориальная кросс-энтропия (logloss) . . . . .	25
3.19	Индекс Джини . . . . .	25
3.20	Метрики регрессии . . . . .	25
3.20.1	Среднеквадратичная ошибка (MSE) . . . . .	25
3.20.2	Среднеабсолютная ошибка (MAE) . . . . .	25
3.20.3	Коэффициент детерминации ( $R^2$ ) . . . . .	26
3.21	Метрики кластеризации . . . . .	26
3.22	Разложение ошибки алгоритма . . . . .	26
3.23	Кривые валидации . . . . .	26
3.24	Кривые обучения . . . . .	26
3.25	Метрические методы . . . . .	26
3.26	Метод ближайших соседей . . . . .	26
3.27	Линейные методы . . . . .	26
3.28	Линейная регрессия . . . . .	26
3.29	Логистическая регрессия . . . . .	26
3.30	SVM . . . . .	27
3.31	Ядра и спрямляющие пространства . . . . .	27
3.32	Решающие деревья . . . . .	27
3.33	Случайный лес . . . . .	28
3.34	Ансамбли алгоритмов . . . . .	28
3.34.1	Идея ансамблирования . . . . .	28
3.35	Градиентный бустинг . . . . .	29
3.36	Байесовские методы . . . . .	29

## 4 Нейросети

# Предисловие

В данной книге описаны основные понятия, методы и подходы, широко используемые в современном DS и ML, встречавшиеся автору на собеседованиях и в ежедневной работе. Обычно, свободное владение этими понятиями необходимо для правильного понимания как основных, так и продвинутых методов ML и по умолчанию предполагается от специалиста в области DS.

Материал подается в виде снippetов - коротких (по возможности) статей. Охвачены такие разделы, как теория вероятностей, классическая и байесовская статистика, некоторые вопросы мат. анализа, общие понятия DS и ML.

Книга представляет собой скорее расширенный глоссарий по основным понятиям ML, чем систематическое изложение какой-либо области. Освещение вопросов ни в коем случае не претендует на полноту и в некоторых случаях на математическую строгость.

# Обозначения

DS	- наука о данных
ML	- машинное обучение
RV	- случайная величина
CDF	- функция распределения случайной величины
PDF	- плотность распределения случайной величины
CLT	- центральная предельная теорема
$EX$	- среднее случайной величины $X$
$DX$	- дисперсия случайной величины $X$
$X \sim Y$	- случайные величины $X$ и $Y$ одинаково распределены

# Глава 1

## Математика

В этой главе описаны основные математические понятия, необходимые для правильного понимания как основных, так и продвинутых методов ML. Охвачены: теория вероятностей, классическая и байесовская статистика, некоторые вопросы мат. анализа.

### 1.1 Случайная величина

Случайной величиной (RV) называется числовая функция  $X$ , определенная на некотором множестве элементарных исходов  $\Omega$  (обычно подмножество  $\mathbb{R}$  или  $\mathbb{R}^n$ ),

$$X : \Omega \rightarrow \mathbb{R}.$$

С прикладной точки зрения на RV часто смотрят как на генераторы случайных чисел с заданным распределением.

**Примеры:**

- Рост людей, взятых из некоторой группы.
- Цвет фиксированного пикселя изображения, взятого из некоторого множества изображений.
- Некоторый признак из датасета ML задачи.

### 1.2 Распределение случайной величины

Если RV принимает дискретное множество значений  $x_1, x_2, \dots$ , то она полностью определяется значениями их вероятностей:  $p_k = \mathbb{P}(X = x_k)$ .

Если множество значений RV не дискретно, то RV может быть описана своей функцией распределения (CDF, Cumulative distribution function):  $F(x) = \mathbb{P}(X < x)$ .

В большинстве прикладных случаев CDF оказывается дифференцируемой функцией. Производная от CDF называется плотностью распределения случайной величины (PDF, Probability density function):  $f(x) = F'(x)$ . Таким образом, по определению

$$\mathbb{P}(a < X < b) = \int_a^b f(x)dx.$$

## 1.3 Выборка

Выборкой объема  $n$  из генеральной совокупности  $X$  называется последовательность независимых и распределенных как  $X$  случайных величин:

$$X_1, X_2, \dots, X_n, \quad X_k \sim X$$

На практике под выборкой понимают конкретные реализации величин  $X_k$ , то есть последовательность чисел  $x_1, x_2, \dots, x_n$ .

## 1.4 Закон больших чисел

Закон больших чисел утверждает, что если  $X_1, X_2, \dots, X_n$  - выборка объема  $n$  из генеральной совокупности  $X$ , то ее среднее с ростом  $n$  становится все менее случайно и в конечном итоге стабилизируется к постоянной величине - среднему значению  $X$ :

$$\frac{X_1 + X_2 + \dots + X_n}{n} \approx \mathbb{E}X, \quad n \rightarrow \infty.$$

## 1.5 Центральная предельная теорема

Центральная предельная теорема (CLT) является в некотором смысле уточнением закона больших чисел. В упрощенном варианте она утверждает, что если  $X_1, X_2, \dots, X_n$  - выборка объема  $n$  из генеральной совокупности  $X$ , то ее распределение ее среднего при больших  $n$  очень близко к нормальному,

$$\frac{X_1 + X_2 + \dots + X_n}{n} \approx N(\mu, \sigma^2/n), \quad \mu = EX, \sigma^2 = DX, \quad n \rightarrow \infty.$$

Заметим, что если совокупность распределена нормально,  $X \sim N(\mu, \sigma^2)$ , то предыдущая формула обращается в точное равенство при любых  $n$ .



## 1.6 Приближенное вычисление интегралов

Пусть  $x_1, x_2, \dots, x_n$  - реализация некоторой выборки из генеральной совокупности  $X$ , распределенной с некоторой плотностью  $f(x)$ . Если  $Y = g(X)$  - случайная величина, являющаяся функцией  $X$ , то ее среднее есть по определению

$$\mathbb{E}Y = \int g(x)f(x)dx.$$

при неизвестной плотности этот интеграл может быть приблизительно вычислен как

$$\mathbb{E}Y \approx \frac{1}{n} \sum_{i=1}^n g(x_i).$$

В частности,

$$\mathbb{E}X \approx \frac{1}{n} \sum_{i=1}^n x_i.$$

## 1.7 Статистики

Пусть  $X_1, X_2, \dots, X_n$  - выборка объема  $n$ . Статистикой называется произвольная RV, являющаяся функцией выборки:

$$T = T(X_1, X_2, \dots, X_n).$$

Часто статистикой называют конкретное значение  $T(x_1, x_2, \dots, x_n)$ , полученное на данной реализации  $x_1, x_2, \dots, x_n$  выборки.

**Примеры:**

- $\bar{X} = (X_1 + X_2 + \dots + X_n)/n$  - выборочное среднее.
- $X_{(n)} = \max(X_1, X_2, \dots, X_n)$  - максимальное значение в выборке.
- медиана, перцентили.

## 1.8 Bootstrap

Пусть имеется реализация некоторой выборки  $x_1, x_2, \dots, x_n$ . Если по каким-либо причинам мы не можем больше сэмплировать из генеральной совокупности, то любая статистика выборки также представляет собой константу:  $T(x_1, x_2, \dots, x_n) = \text{const}$ .

Бутстрепом называется процесс сэмплирования из имеющейся выборки  $x_1, x_2, \dots, x_n$  подвыборки длины  $n$  с возвращением. Проведя эту операцию  $k$  раз, можем, в частности, посчитать  $k$  значений интересующей нас статистики, то есть фактически исследовать ее возможные эмпирические значения.

Бутстреп позволяет получать эмпирические распределения интересующих нас величин, получать точечные и интервальные оценки, выравнивать количества несбалансированных выборок при А/В тестировании и многое другое.

При однократном выполнении данной процедуры мы используем в среднем только  $1 - 1/e \approx 63\%$  всей выборки, что обычно используется в out-of-bag оценках различных алгоритмах, основанных на бутстрепах.

## 1.9 Классический и байесовский подход

Основные отличия между классическим (частотным) и байесовским подходом отражены в следующей таблице:

	Частотный подход	Байесовский подход
Идеология	Объективная случайность существует	Любая случайность субъективна
Объект	Неслучайные параметры случайных величин	Распределения случайных величин
Метод	Метод максимального правдоподобия	Теорема Байеса
Результат	Точечные и интервальные оценки неизвестных параметров	Распределение неизвестных параметров
Применимость	Размер выборки велик по сравнению с кол-вом неизвестных параметров	Размер выборки любой

Иными словами, в байесовском подходе любая неизвестная величина считается случайной с некоторым распределением, которое затем может уточняться вогласно новым данным по теореме Байеса.

## 1.10 Классическая оценка параметров: MLE

Пусть имеется выборка значений  $D = \{x_1, x_2, \dots, x_n\}$  некоторой величины  $X$ , точное распределение которой нам неизвестно. Предполагаем, что плотность распределения  $X$  известна с точностью до параметра  $\alpha$  (возможно, многомерного):

$$X \sim g(x, \alpha).$$

Величина

$$L(\alpha|D) = g(D|\alpha) = \prod_{i=1}^n g(x_i|\alpha)$$

называется **правдоподобием** и представляет собой плотность/вероятность получить именно такие данные  $D$  из распределения исходной величины  $X$ . Естественнo пытаться определить неизвестный параметр  $\alpha$  как тот, при котором эта вероятность максимальна. Правдоподобие обычно логарифмируют, что не влияет на

оптимальное значение параметра:

$$\alpha_{MLE} = \operatorname{argmax} \ln L(\alpha|D).$$

## 1.11 Байесовская оценка параметров: MAP

Пусть имеется выборка значений  $D = \{x_1, x_2, \dots, x_n\}$  некоторой величины  $X$ , точное распределение которой нам неизвестно. Предполагаем, что плотность распределения  $X$  известна с точностью до параметра  $\alpha$  (возможно, многомерного):

$$X \sim g(x, \alpha).$$

Согласно *байесовской парадигме*, неизвестный параметр  $\alpha$  трактуется не как число, а как случайная величина, имеющая некоторое распределение:  $\alpha \sim f(\alpha)$ . Это исходное распределение параметра может быть уточнено с учетом пришедших данных  $D$  по формуле Байеса:

$$f(\alpha|D) = \frac{g(D|\alpha)f(\alpha)}{h(D)}.$$

Здесь  $f$  - априорное распределение  $\alpha$ ,  $g(D|*)$  - правдоподобие пришедших данных  $D$ ,  $h$  - evidence - плотность/вероятность получения именно таких данных.

Процедуру уточнения распределения неизвестных параметров можно повторять по мере получения новых данных, используя полученное на предыдущем шаге апостериорное распределение как априорное для следующего.

MAP оценкой параметра  $\alpha$  называется значение

$$\alpha_{MAP} = \operatorname{argmax} f(\alpha|D).$$

Важно понимать, что байесовский подход дает оценку не плотности распределения исходных данных  $g$  напрямую, а оценку плотности распределения некоторого параметра распределения  $g$ .

Известными минусами байесовского подхода является необходимость откуда-то брать априорное распределение параметра  $f(\alpha)$  и вычисление знаменателя  $h(D)$ , что является обычно вычислительно сложной задачей. Тем не менее, обычно выбор априорного распределения не оказывает сильного влияния на результат, а знаменатель  $h(D)$ , будучи не зависимой от  $\alpha$ , не влияет на  $\alpha_{MAP}$ .

## 1.12 Сравнение классической и байесовской оценок параметров

Пусть имеется выборка значений  $D = \{x_1, x_2, \dots, x_n\}$  некоторой величины  $X$ , точное распределение которой нам неизвестно. Предполагаем, что плотность распределения  $X$  известна с точностью до параметра  $\alpha$  (возможно, многомерного):

$$X \sim g(x, \alpha).$$

Согласно *классическому подходу*, величина  $\alpha$  трактуется как фиксированное (хоть и неизвестное) число, которое находится исходя из желания максимизировать вероятность того, что исходные данные  $D$  пришли именно из этого распределения.

Согласно *байесовскому подходу*, величина  $\alpha$  трактуется как случайная с некоторым известным априорным распределением. Основной целью в этом случае выступает нахождение апостериорного распределения величины  $\alpha$ , уточненного согласно пришедшим данным  $D$  по формуле Байеса.

Если интервал изменения неизвестного параметра  $\alpha$  конечен, а о самом  $\alpha$  мы не имеем никаких априорных знаний, естественно положить априорное распределение  $\alpha$  равномерным. В этом случае результаты байесовской и классической оценок совпадают:  $\alpha_{MLE} = \alpha_{MAP}$ .

## 1.13 Классический доверительный интервал

## 1.14 Байесовский доверительный интервал

## 1.15 Основные дискретные распределения

<https://medium.com/@srowen/common-probability-distributions-347e6b945ce4>

## 1.16 Основные непрерывные распределения

## 1.17 Метод Монте-Карло

## 1.18 Байесовская оптимизация

## 1.19 Матричные разложения

...может разделить главу на части...

## 1.20 К-Л дивергенция

Дивергенция Кульбака-Лейблера (относительная энтропия) - мера сходства двух распределений. Для RV  $P, Q$  вычисляется как

$$K(p, q) = - \sum_{i=0}^n p_i \log_2 \frac{q_i}{p_i}.$$

Определено для распределений  $q_i = 0 \Rightarrow p_i = 0$ . В байесовской интерпретации это информация, приобретенная при переходе от априорного распределения  $p$  к апостериорному распределению  $q$ .

К-Л дивергенция всегда неотрицательна и аддитивна в следующем смысле: если  $P_1, P_2$  - независимые RV,  $Q_1, Q_2$  - тоже, то для совместных плотностей распределения  $P$  и  $Q$  справедливо:

$$K(P, Q) = K(P_1, Q_1) + K(P_2, Q_2).$$

К-Л дивергенция может использоваться как метрика между распределениями, так как при  $n \rightarrow \infty$  справедливо

$$K(P_n, Q) \rightarrow 0 \quad \Rightarrow \quad P_n \rightarrow Q$$

в смысле распределений.

## 1.21 Энтропия

## 1.22 Кросс-энтропия

## 1.23 Квантили

## 1.24 Точечные оценки

## 1.25 Интервальные оценки

## 1.26 Проверка гипотез \*\*\*

Пусть  $x_1, x_2, \dots, x_n$  - выборка из генеральной совокупности  $X$ , распределение которой заранее неизвестно. Требуется проверить некоторое утверждение о распределении генеральной совокупности  $X$  исходя из имеющейся выборки.

Общий подход к решению таких задач состоит в следующем:

1. Формулируется основная гипотеза  $H_0$  о распределении  $X$  и некоторая альтернативная гипотеза  $H_1$ , которая может являться полным отрицанием  $H_0$  (двусторонняя альтернатива), но не обязательно (односторонние и др. альтернативы).
2. Выбирается некоторая статистика  $T$  исходя из условия, что нулевая гипотеза  $H_0$  верна тогда и только тогда, когда распределение  $T$  известно:  $T \sim F(t|H_0)$  (нулевое распределение статистики).

3. Вычисляется значение  $t^*$  статистики  $T$  на имеющейся выборке. По известному распределению  $F$  можно судить, насколько вероятно получить значения  $t^*$ .
4. Выбирается уровень значимости  $\alpha$ .
5. Вычисляется достигаемый уровень значимости  $p_{value}$  и сравнивается с  $\alpha$ . Если  $p_{value} > \alpha$ , то нулевая гипотеза  $H_0$  не может быть отвергнута, а если  $p_{value} \leq \alpha$ , гипотеза  $H_0$  отвергается в пользу альтернативной  $H_1$ .

#### Пример: TODO

Обычно нулевая гипотеза  $H_0$  означает, что "ничего интересного не происходит а альтернативная, напротив, говорит о том, что "что-то произошло".

## 1.27 Достигаемый уровень значимости, $p_{value}$ \*\*\*

Пусть статистика  $T$  приняла на выборке  $x_1, x_2, \dots, x_n$  значение  $t^*$ . Так как нулевое распределение статистики известно, по значению  $t^*$  можно судить, насколько оно характерно для данного распределения. Именно, для случая правосторонней альтернативной определим значение

$$p_{value} = \mathbb{P}(T \geq t^* | H_0).$$

TODO картинка

Если бы  $H_0$  была справедлива, то значение  $t^*$  вероятно оказалось бы около математического ожидания распределения  $T$  и, как следствие,  $p_{value}$  было бы велико. В противном случае, если  $t^*$  оказалось далеко правее среднего,  $p_{value}$  мало, и нулевую гипотезу следует отвергнуть в пользу правосторонней альтернативы  $H_1$ .

Число  $p_{value}$  называется достигаемым уровнем значимости. Оно сравнивается с заранее заданным уровнем значимости  $\alpha$ , и если  $p_{value} > \alpha$ , то нулевая гипотеза  $H_0$  не может быть отвергнута, а если  $p_{value} \leq \alpha$ , гипотеза  $H_0$  отвергается в пользу альтернативной  $H_1$ .

Аналогичные рассуждения справедливы для случаев лево- и двусторонней альтернативы.

## 1.28 Множественная проверка гипотез

Пусть имеется ряд статистических гипотез, которые следует проверить в совокупности, то есть совокупная нулевая гипотеза состоит в том, что во все исходные нулевые гипотезы верны. Пусть  $\alpha$  - уровень значимости для всех исходных гипотез. Определить тем же уровнем значимости для совокупной гипотезы было бы

неверно, так как отвергание совокупной нулевой гипотезы означало бы, что хотя одна из исходных гипотез отвергается. Вероятность этого события

$$1 - (1 - \alpha)^m,$$

экспоненциально близка к 1 при больших  $m$ . Таким образом, вероятность совершить ошибку первого рода для множественной проверки гипотез всегда очень близка к 1, если использовать тот же уровень значимости, что и для исходных гипотез.

**Пример:** Некоторое лекарство исследуется на  $m$  возможных побочных эффектов. Чем больше  $m$ , тем выше вероятность, что хотя один побочный эффект проявится. Это не означает, что этот побочный эффект характерен для лекарства, он мог проявиться просто случайно.

## 1.29 Коррекции на множественную проверку гипотез

## 1.30 Ошибки I и II рода

## 1.31 Уровень значимости, $\alpha$

Уровень значимости  $\alpha$  - вероятность ошибки первого рода, то есть вероятность отвергнуть верную нулевую гипотезу.

## 1.32 Мощность статистического критерия

Пусть  $\beta$  - вероятности ошибки второго рода, то есть вероятности принять неверную нулевую гипотезу. Величина  $1 - \beta$  называется мощностью статистического критерия. Таким образом, мощность статистического критерия - это вероятность отвергнуть неверную нулевую гипотезу.

## 1.33 Основные задачи статистики

...из лекций новосиба курсера...

- 1.34 Параметрические и непараметрические критерии, бутстреп
- 1.35 Проверка основных гипотез
- 1.36 Корреляция Пирсона
- 1.37 Корреляция Спирмена
- 1.38 Корреляция Метьюса
- 1.39 Корреляция Крамера
- 1.40 Z-тест Фишера
- 1.41 T-тест Стьюдента
- 1.42 Критерий Пирсона  $\chi^2$
- 1.43 Точный тест Фишера
- 1.44 Проклятие размерности



## Глава 2

# Анализ данных

Анализ и предобработка данных - первая задача, успешное решение которой зачастую определяет успех в решении любых задач ML. В этой главе описываются основные подходы....

### 2.1 Типы данных

### 2.2 Предобработка данных

### 2.3 Понижение размерности

# Глава 3

## Общие вопросы

В этой главе приводятся основные понятия ML и DS.

### 3.1 Машинное обучение

Машинное обучение (ML) - область искусственного интеллекта, изучающая самообучающиеся модели, то есть решающие поставленную задачу не по заранее запрограммированному алгоритму, а предварительно настраивая свое поведение согласно имеющимся данным.

Обычно методы ML содержат свободные параметры, подбор которых наилучшим (в смысле имеющихся данных и задачи) образом и составляет процесс обучения алгоритма. После обучения алгоритм можно использовать на новых данных, которые не были представлены алгоритму на стадии обучения.

### 3.2 Эмпирический риск

Будем считать, что обучающая выборка  $(x_1, y_1), (x_2, y_2), \dots (x_n, y_n)$  приходит из некоторого распределения с плотностью  $f(x, y)$ . Пусть, далее, задано зависящее от параметра семейство алгоритмов  $a = a(x, w)$  и некоторая функция потерь  $L = L(y, a)$ .

В этих условиях общая задача обучения с учителем может быть формализована как задача минимизации риска, то есть средней ошибки

$$l(w) \equiv \mathbb{E}L = \int L(y, a(x, w))f(x, y)dxdy,$$

$$w_{opt} = \operatorname{argmin} l(w).$$

Само распределение  $f$  обычно не известно, однако, при условии, что обучающая выборка пришла из этого распределения, интеграл можно приближенно заменить

средним и таким образом оценить среднюю ошибку через *эмпирический риск*

$$r_{emp}(w) = \frac{1}{n} \sum_{i=1}^n L(y_i, a(x_i, w)) \approx l(w).$$

Таким образом, основную задачу обучения можно пытаться решать минимизацией эмпирического риска вместо полного.

### 3.3 Основные классы задач

#### 3.3.1 Обучение с учителем

#### 3.3.2 Обучение без учителя

#### 3.3.3 Частичное обучение

#### 3.3.4 Обучение с подкреплением

### 3.4 Обнаружение аномалий

### 3.5 Контроль качества

...оценка обобщающей способности...

## 3.6 Недообучение

## 3.7 Переобучение

## 3.8 Регуляризация

## 3.9 Отбор признаков

## 3.10 Параметры алгоритма

## 3.11 Подбора метапараметров

## 3.12 Основные типы алгоритмов

## 3.13 Многоклассовая классификация

В задачах многоклассовой классификации каждый объект  $x$  требуется отнести к двум или более классам  $1, 2, \dots, K$ . Такого рода задачи могут решаться как алгоритмами, способными сразу работать с любым числом классов, так и сведением к нескольким задачам бинарной классификации.

Подходы к решению:

1. Использовать алгоритмы, способные сразу выдавать вектор оценок принадлежности объекта к каждому классу (нейросети, ближайшие соседи и пр.).
2. One-vs-All: Решить  $K$  задач по отделению  $i$ -го класса от всех остальных. В качестве оценки принадлежности объекта классу  $i$  следует выбрать ответ  $i$ -го алгоритма на этом объекте:

$$p(i|x) = a_i(x).$$

Плюс в небольшом числе обучаемых классификаторов. Минус в том, что обучающие выборки становятся несбалансированными.

3. One-vs-One: Решить  $K(K-1)/2$  задач бинарной классификации для каждой пары классов. В качестве оценки принадлежности объекта классу  $i$  следует взять сумму оценок принадлежностей этому классу всех алгоритмов, отделяющих  $i$ -й класс от остальных:

$$p(i|x) = \sum_{j \neq i} a_{ij}(x).$$

Плюс в том, что обучающие выборки сохраняют сбалансированность. Минус в том, что число обучаемых классификаторов квадратично велико.

4. Error-Correcting Output Code (ECOC): Закодировать каждый класс вектором из нулей и единиц некоторого размера  $k$  ( $k \geq \log_2 K$ ). Кодировочные векторы следует выбирать так, чтобы они образовывали коды, исправляющие ошибки. Обучаем  $k$  бинарных классификаторов. На этапе предсказания для объекта формируем  $k$ -мерный вектор и относим его к тому классу, расстояние Хэмминга до которого минимально.

### 3.14 Дисбаланс классов

...чем плохо... как бороться (over/undersampling/SMOTE)...

### 3.15 Ансамбли алгоритмов

### 3.16 Метрики и функции потерь

Метрика - величина, обычно диктуемая бизнесом, оптимизация (максимизация или минимизация) которой вполне очевидным образом свидетельствует об улучшении качества работы модели.

Функция потерь - величина, более удобная для оценки/оптимизации модели, уменьшение которой, вообще говоря, приводит к оптимизации метрики задачи.

Иными словами, улучшение метрики - конечная цель процесса обучения алгоритма, но достигается это зачастую оптимизацией именно некоторой функции потерь, с которой может быть удобнее работать. Метрики и функции потерь - близкие понятия, когда речь идет об оценке качества алгоритма, и их довольно часто смешивают.

**Пример:** Пусть в задаче бинарной классификации основной метрикой является ассигасу - доля правильных ответов. Эта метрика не дифференцируема, поэтому ее оптимизация напрямую методами гладкой оптимизации невозможна. В качестве функции потерь выберем MSE - среднеквадратичную ошибку. Это уже гладкая функция своих аргументов, и ее минимизация скорее всего приведет к увеличению доли правильных ответов, то есть к конечной цели.

### 3.17 Метрики бинарной классификации

Пусть некоторый алгоритм  $a$  решает задачу бинарной классификации с классами 0 (негативный) и 1 (позитивный). Тестирование алгоритма  $a$  проводится на  $n$  объектах, ответы  $y$  на которых известны. Пусть  $TP$  и  $TN$  - числа правильно классифицированных позитивных и негативных объектов соответственно. Аналогично,  $FP$  и  $FN$  - числа неправильно классифицированных позитивных и негативных объектов соответственно.

О качестве алгоритма  $a$  можно судить по матрице ошибок:

	y=1	y=0
a=1	TP	FP
a=0	FN	TN

Для оценки качества работы алгоритмов бинарной классификации обычно используются описанные далее основные метрики.

### 3.17.1 Accuracy

Точность (accuracy) - доля правильных ответов,

$$accuracy = \frac{TP + TN}{n}.$$

Проста в использовании и интерпретации, но плоха для несбалансированных выборок. Кроме того, не дифференцируема и потому не может быть использована напрямую в качестве функции потерь для алгоритмов гладкой оптимизации.

### 3.17.2 Precision

Точность (precision) - отношение числа правильно классифицированных позитивных объектов к общему количеству позитивно классифицированных,

$$precision = \frac{TP}{TP + FP}.$$

Чем ближе значение к 1, тем меньше ложных срабатываний (FP). Проста в использовании и интуитивна, то не использует информацию о негативно классифицированных объектах и, кроме того, не является дифференцируемой.

### 3.17.3 Полнота (recall)

Полнота (recall) - вычисляется как отношение

$$recall = \frac{TP}{TP + FN}.$$

Чем ближе значение к 1, тем меньше ложных пропусков (FN). Проста в использовании и интуитивна, то не использует TN, FP и, кроме того, не является дифференцируемой.

### 3.17.4 F1-мера

F1-мера - среднее гармоническое точности и полноты,

$$F = \frac{2PR}{P + R}.$$

F1-мера усредняет точность и полноту, является неплохим компромиссом между обеими метриками. Проста в использовании, но плохо интерпретируема и не является дифференцируемой.

### 3.17.5 F-мера

Обобщенная F-мера вычисляется как

$$F = (1 + \beta^2) \frac{PR}{\beta^2 P + R}.$$

F-мера усредняет точность и полноту, является неплохим компромиссом между обеими метриками, имеет настраиваемый параметр  $\beta$ . Проста в использовании, но плохо интерпретируема и не является дифференцируемой.

### 3.17.6 ROC кривая

ROC кривая - характеристика качества алгоритмов бинарной классификации, дающих вероятностноподобный вывод,  $a \in [0, 1]$ . ROC кривая строится в координатах

$$FPR = \frac{FP}{FP + TN}, \quad TPR = \frac{TP}{TP + FN}.$$

Каждая точка кривой - значение  $(FPR, TPR)$ , полученное для некоторого порога дискретизации алгоритма (см. 3.17.8).


Более простой способ построения ROC кривой состоит в следующем:

1. отрезки  $[0, 1]$  по осям  $TPR$  и  $FPR$  разбиваются на  $\#[y = 0]$  и  $\#[y = 1]$  частей соответственно.
2. пары реальных ответов  $y_i$  упорядочиваются по убыванию соответствующих ответов алгоритма  $a_i$ .
3. проходя по получившемуся после сортировки массиву значений  $y_i$ , строим ROC кривую, начиная от начала координат и делая шаг вправо, если  $y_i = 0$  и вверх, если  $y_i = 1$ . Важный момент: если рядом по порядку оказались несколько  $a_i$  с одинаковыми значениями, то соответствующий им участок ROC кривой будет не ступенчатым, а прямолинейным (см. пример ниже).

ROC кривая идеального алгоритма проходит через точки  $(0, 0)$ ,  $(0, 1)$ ,  $(1, 1)$ ; для случайного гадания - проходит вблизи прямой  $FPR = TPR$ . Наилучшим значением порога дискретизации алгоритма может считаться порог, соответствующий точке на ROC кривой, ближайшей к  $(0, 1)$ , либо точке, наиболее удаленной от прямой случайного гадания  $TPR = FPR$ .

**Пример:** для алгоритма, дающего вывод как в таблице ниже, график ROC кривой выглядит следующим образом

y	1	0	0	1	0	1	0
a	1.0	0.9	0.9	0.9	0.8	0.3	0.2



### 3.17.7 ROC-AUC

ROC-AUC - площадь под ROC кривой. Применяется к алгоритмам бинарной классификации, дающим вероятностноподобный вывод,  $a \in [0, 1]$ , позволяя оценить алгоритм "в целом без привязки к конкретному значению порога дискретизации алгоритма.

ROC-AUC принимает значения от 0 до 1. Значения близкие к 0.5 интерпретируются как самые худшие (случайное гадание), близкие к 1 - как хорошие. ROC-AUC более устойчива к дисбалансу классов, чем Ассигасу, но не так хорошо, как PR-AUC. ROC-AUC также не учитывает уверенность алгоритма в своих предсказаниях (насколько близко распределены предсказания к 0 и 1). Не является дифференцируемой.

ROC-AUC для примера 3.17.6 равна  $2/3$ .

### 3.17.8 PR кривая

PR кривая - характеристика качества алгоритмов бинарной классификации, дающих вероятностноподобный вывод,  $a \in [0, 1]$ . PR кривая строится в координатах

$$recall = \frac{TP}{TP + FN}, \quad precision = \frac{TP}{TP + FP}.$$

Каждая точка кривой - значение  $(recall, precision)$ , полученное для некоторого порога дискретизации алгоритма.

Способ построения PR кривой состоит в следующем:

1. вычисляются пороги  $h$  - всевозможные значения ответов алгоритма  $a$ .
2. ответы  $a_i$  дискретизируются для каждого значения порога и вычисляются значения  $recall$  и  $precision$ . При этом ордината первой точки кривой, соответствующей порогу  $h > 1$ , не определена, так как знаменатель  $precision$  обращается в ноль. В качестве ординаты берется ордината второй точки.
3. по полученным точкам строится график PR кривой.



PR кривая идеального алгоритма проходит через точки  $(0, 1)$ ,  $(1, 1)$ ,  $(1, \# [y = 1]/n)$ ; для случайного гадания - проходит вблизи прямой  $precision = \# [y = 1]/n$ .

**Пример:** для алгоритма, дающего вывод как в таблице ниже, график PR кривой выглядит следующим образом

y	1	0	0	1	0	1	0
a	1.0	0.9	0.9	0.9	0.8	0.3	0.2



### 3.17.9 PR-AUC

PR-AUC - площадь под PR кривой. Применяется к алгоритмам бинарной классификации, дающим вероятностноподобный вывод,  $a \in [0, 1]$ , позволяя оценить алгоритм "в целом без привязки к конкретному значению порога дискретизации алгоритма.

PR-AUC - площадь под PR кривой. Принимает значения от 0 до 1. Значения близкие к 1 интерпретируются как хорошие, близкие к  $\# [y = 1]/n$  - как самые худшие (случайные гадания). PR-AUC более устойчива к дисбалансу классов, чем ROC-AUC, однако, не учитывает уверенность алгоритма в своих предсказаниях (насколько близко распределены предсказания к 0 и 1). Не является дифференцируемой.

PR-AUC для примера 3.17.8 равна  $11/15 \approx 0.73$ .

#### 3.17.10 Бинарная кросс-энтропия (logloss)

Пусть  $y$  - истинная метка объекта (0 или 1),  $a$  - ответы некоторого алгоритма (число из  $[0, 1]$ ). Бинарная кросс-энтропия (logloss) вычисляется как

$$L(y, a) = -y \log_2 a - (1 - y) \log_2(1 - a).$$

Слагаемые с нулевым множителем при логарифме (соответствующие  $y = 0$  и  $y = 1$ ) полагаются равными нулю.

Полная кросс-энтропия на множестве ответов определяется усреднением значений по всем объектам.

Бинарная кросс-энтропия имеет следующую вероятностную интерпретацию. Пусть метка  $i$ -му объекту назначается по схеме Бернулли, т.е. метка полагается

равной  $y_i = 1$  с вероятностью  $a_i$  и  $y_i = 0$  с вероятностью  $1 - a_i$ . Тогда вероятность получить истинные ответы  $y_i$  равна

$$\prod_{i=1}^n a_i^{y_i} (1 - a_i)^{1-y_i}.$$

Логарифмируя, получаем правдоподобие, совпадающее с бинарной кросс-энтропией с точностью до знака. Таким образом, нахождение ответов  $a_i$  с позиции минимизации бинарной кросс-энтропии равносильно максимизации правдоподобия.

[https://en.wikipedia.org/wiki/Loss\\_functions\\_for\\_classification](https://en.wikipedia.org/wiki/Loss_functions_for_classification)

## 3.18 Метрики многоклассовой классификации

### 3.18.1 Категориальная кросс-энтропия (logloss)

## 3.19 Индекс Джини

## 3.20 Метрики регрессии

### 3.20.1 Среднеквадратичная ошибка (MSE)

Пусть  $y$  - истинная метка объекта, а  $a$  - ответы некоторого алгоритма. Квадратичная ошибка вычисляется как

$$L(y, a) = (y - a)^2.$$

Полная среднеквадратичная ошибка на множестве ответов определяется усреднением значений по всем объектам. Наилучшим константным предсказанием для MSE является выборочное среднее:

$$a = \frac{1}{n} \sum_{i=1}^n y_i$$

MSE дифференцируема и проста в использовании, но плохо интерпретируема, так как дает ненормированный ни к чему результат, который трудно с чем-либо сравнить. Кроме того, MSE чувствительна к выбросам в выборке.

### 3.20.2 Среднеабсолютная ошибка (MAE)

Пусть  $y$  - истинная метка объекта, а  $a$  - ответы некоторого алгоритма. Абсолютная ошибка вычисляется как

$$L(y, a) = |y - a|.$$

Полная среднеквадратичная ошибка на множестве ответов определяется усреднением значений по всем объектам. Наилучшим константным предсказанием для MSE является выборочная медиана.

MAE проста в использовании, но недифференцируема и плохо интерпретируема, так как дает ненормированный ни к чему результат, который трудно с чем-либо сравнить. MAE менее чувствительна к выбросам в выборке, чем MSE.

### 3.20.3 Коэффициент детерминации ( $R^2$ )

Пусть  $y_i$  - истинные метки объектов  $x_i$ , а  $a_i$  - ответы некоторого алгоритма. Коэффициент детерминации  $R^2$  вычисляется как

$$R^2(y, a) = 1 - \frac{\sum_{i=1}^n (y_i - a_i)^2}{\sum_{i=1}^n (y_i - \hat{y})^2}, \quad \hat{y} = \frac{1}{n} \sum_{i=1}^n y_i.$$

$R^2$  показывает долю дисперсии  $y_i$ , объясняемую моделью. Является по сути линейной функцией от MSE, но более интерпретируема в силу нормировки к результату с константным прогнозом  $\hat{y}$ . Минусом является увеличение  $R^2$  при увеличении числа признаков, что далеко не всегда свидетельствует о увеличении качества модели.

## 3.21 Метрики кластеризации

## 3.22 Разложение ошибки алгоритма

## 3.23 Кривые валидации

## 3.24 Кривые обучения

## 3.25 Метрические методы

## 3.26 Метод ближайших соседей

## 3.27 Линейные методы

## 3.28 Линейная регрессия

## 3.29 Логистическая регрессия

...отличие от линейной...

### 3.30 SVM

### 3.31 Ядра и спрямляющие пространства

### 3.32 Решающие деревья

Решающее дерево - бинарное дерево, во внутренних вершинах которого стоят предикаты  $\beta : X \rightarrow \{0, 1\}$ , а в листовых вершинах - элементы множества ответов  $Y$  (классы для задач классификации и числа для регрессии).

В качестве предикатов обычно используются простые линейные индикаторы  $\beta_{jt}(x) = [x^j < t]$  ( $j$ -й признак меньше порога  $t$ ).

Базовый алгоритм построения дерева решений (ID3 алгоритм):

1. Начинаем со всей обучающей выборки  $U = x_{(1)}, \dots, x_{(n)}$ .
2. Проверяем, не выполнен ли для текущей вершины некоторый критерий останова (максимальное число листьев, минимальное число объектов в вершине, все объекты одного класса и пр.). Если это так, то объявляем вершину листовой, помещая в нее в качестве предсказания наиболее многочисленный класс (для задачи классификации), либо среднее из ответов (для регрессии).
3. Если критерий останова не выполнен, вершина объявляется внутренней. В нее помещается выбираем предикат, максимизирующий функционал качества

$$(j, t) = \operatorname{argmax} Q(U, j, t), \quad Q(U, j, t) = H(U) - \frac{|U_l|}{|U|} H(U_l) - \frac{|U_r|}{|U|} H(U_r),$$

где  $U_l, U_r$  - подмножества выборки  $U$ , удовлетворяющие и не удовлетворяющие предикату  $\beta_{jt}$  соответственно,  $H$  - некоторый критерий информативности (см. ниже). Информативность стремимся минимизировать, функционал качества, соответственно - максимизировать.

4. Строим левое и правое поддерево, рекурсивно повторяя шаги 2-4 для подвыборок  $U_l, U_r$ .

Приведенный алгоритм - жадный, так как на каждом шаге он старается максимизировать функционал качества, не заботясь о том, будет ли это оптимальным выбором в целом.

Пусть  $p_k$  - доля объектов класса  $k$  в выборке  $U$  (части обучающей выборки, попавшей в любую вершину). Примеры критериев информативности:

1.  $H(U) = 1 - \max_k p_k$  - ошибка классификации,
2.  $H(U) = \sum_{k=1}^K p_k(1 - p_k)$  - критерий Джини,
3.  $H(U) = -\sum_{k=1}^K p_k \log p_k$  - энтропийный критерий.

Достоинства решающих деревьев:

- хорошая интерпретируемость,
- допускаются пропуски в данных,
- высокая скорость обучения и работы.

Недостатки:

- склонность к переобучению,
- низкая статистическая значимость глубоких деревьев (выборка все меньше дальше от корня),
- чувствительность к шуму и выбору критерия информативности.

С переобучением решающих деревьев обычно борются стрижкой (pruning), либо объединением деревьев в ансамбли - случайный лес.

### 3.33 Случайный лес

...отличие от беггинга над решающими деревьями...

### 3.34 Ансамбли алгоритмов

#### 3.34.1 Идея ансамблирования

Ансамблем алгоритмов называется алгоритм, использующий в своей работе другие (базовые) алгоритмы. Простейший пример ансамбля в задачах классификации - комитет большинства:

$$a(x) = \text{mode}(a_1(x), \dots, a_n(x)).$$

Простейший пример ансамбля в регрессии - среднее ответов некоторых алгоритмов:

$$a(x) = \frac{1}{n} \sum_{j=1}^n a_j(x).$$

Если алгоритмы  $a_i$  независимы как случайные величины (функции случайной величины  $x$  - объекта предсказания), имеют одинаковые средние и ограниченные одним числом  $d$  дисперсии, то ансамбль  $a$  будет иметь то же среднее и меньшую дисперсию:

$$\mathbb{E}a = \mathbb{E}a_j, \quad \mathbb{D}a \leq \frac{d}{n}.$$

Таким образом, независимые алгоритмы в среднем подавляют ошибки друг друга, уменьшая тем самым разброс значений.

Более сложные примеры ансамблей обычно включают в себя обучение базовых алгоритмов на различных подвыборках исходной обучающей выборки, своем подмножестве признаков и др. Также при ансамблировании алгоритмов следует учитывать возможное переобучение, связанное с тем, что мы в итоге настраиваем результирующий алгоритм, используя информацию обо всей обучающей выборке. Для оценки качества ансамбля лучше сохранять некоторую валидирующую часть обучающей выборки, невидимую для всех базовых алгоритмах на этапе их обучения.

### 3.35 Градиентный бустинг

### 3.36 Байесовские методы

## Глава 4

# Нейросети

В данной главе приводится обзор основных понятий и методов, связанных с нейросетями.